

Planeringsrapport

Titel

Can a Biologically Informed Neural Network Outperform a Conventional Deep Neural Network at Classifying Alzheimer's Disease Status from Post-Mortem Brain Single-Cell Data?

Kan ett biologiskt informerat neuralt nätverk prestera bättre än ett konventionellt neuralt nätverk, vad gäller att klassificera sjukdomsstatus för Alzheimers sjukdom utifrån Single-Cell data från post-mortem hjärnceller?

Bakgrund

Alzheimers sjukdom

Alzheimers är den vanligaste demenssjukdomen, och orsakas av skador på hjärnans nervceller. I sjukdomens tidiga stadium kan mildare grad av symtom såsom försämring av minne, språk och tänkande uppstå. Det kan vara möjligt att diagnostisera sjukdomen redan i detta stadium om symtomen uppmärksammas av den drabbade eller personer i dess närhet, men ofta brukar en diagnos ställas först efter att symtomen blivit omfattande nog att börja påverka personens dagliga liv. Redan 20 år före detta kan hjärnan ha börjat förändras (Alzheimer's Association, 2024 och *Alzheimer's Stages - Early, Middle, Late Dementia Symptoms* | [Alz.org](https://www.alz.org), n.d.).

Alzheimers är en progressiv sjukdom, vilket betyder att den över tid sprider sig till flera delar av hjärnan. Hur snabbt sjukdomen framskrider varierar mellan individer. Efter en tid kan den som är sjuk behöva hjälp för att klara av vardagsaktiviteter som att äta, klä sig och att sköta sin hygien. I slutskedet av sjukdomen påverkas basala motoriska kroppsfunktioner som att svälja, tala eller gå. I genomsnitt lever en person med Alzheimers i 4-8 år efter sin diagnos, men det går att leva upp till 20 år med sjukdomen. Vanligtvis dör patienten inte av Alzheimers i sig, utan av någon annan orsak. Samsjuklighet med andra sjukdomstillstånd, som diabetes eller njursjukdom, tenderar att förkorta livslängden och försvåra vård (Alzheimer's Association, 2024).

Globalt lever 55 miljoner personer med någon form av demenssjukdom, varav uppskattningsvis 60-80% av dem har Alzheimers. Demenssjukdomar har stor påverkan på både den drabbade och dennes familj och närstående. Med en åldrande befolkning i stora delar av världen ökar också antalet personer som lever med Alzheimers och andra demenssjukdomar, vilket innebär en ökad belastning på vårdsystemen (Alzheimer's Association, 2024). Det finns idag läkemedel som, åtminstone temporärt eller för vissa patienter, kan lindra symtomen eller sakta ner progressionen. Däremot saknas botemedel eller förebyggande läkemedel (Alzheimer's Association, 2024, *Navigating Treatment Options* | [Alz.org](https://www.alz.org), 2026). Eftersom Alzheimers är den vanligaste formen av demenssjukdom globalt, förutses drabba en större andel av befolkningen (Hao & Chen, 2025), samt orsakar svårigheter på både personligt och samhälleligt plan, är det en intressant sjukdom att studera för att bättre förstå dess mekanismer och hitta möjliga behandlingsmetoder.

Genuttryck (Gene Expression)

Genuttryck är den process som avkodar genens information till protein, genom transkription från DNA till RNA. RNA kan translateras till protein eller utföra andra roller i cellen. Genuttryck kan styra både *om* en gen avkodas och *hur mycket* en gen avkodas. Regleringen av genuttrycket varierar under olika förutsättningar och från celltyp till celltyp. Både RNA och de proteiner som produceras kan i sin tur styra hur andra gener uttrycks (National Human Genome Research Institute, 2026).

Biologiska reaktionsvägar och nätverk

Med *biologiska reaktionsvägar* (Biological pathways) menas de interaktioner mellan en serie molekyler som leder till förändringar i en cell, eller som leder till att någon form av produkt skapas. Ett exempel är just de reaktionsvägar som reglerar genuttryck. Oftast har ett antal olika biologiska reaktionsvägar interaktioner sinsemellan, och bildar då *biologiska nätverk* (National Human Genome Research Institute (NHGRI), 2020). Reaktionsvägar och nätverk finns bland annat dokumenterade i databaser som Reactome, Gene Ontology och KEGG (Selby et al., 2025).

Single-Cell Omics

Omics är studier som syftar till att kartlägga det totala innehållet av någon biomolekyl eller molekylär process i en organism. Det finns ett flertal olika grenar av omics, däribland transcriptomics (det totala innehållet av RNA) och proteomics (det totala innehållet av proteiner) (Rogers & Griffiths, n.d.). Inom Single-cell omics intresserar man sig för att kvantifiera förekomsten av någon molekyl i (vanligtvis ett stort antal) individuella celler, vilket möjliggörs av nya teknologier (NGS, Next Generation Sequencing) som låter forskare undersöka enskilda celler med hög upplösning. Detta är i kontrast till tidigare teknologier, som endast gav möjligheten att analysera celler i bulk. Sådana analyser gav information om genomsnittet av det molekylära innehållet i en samling celler, vilket begränsade deras nytta jämfört med de nya metoderna. Single-cell omics har potentialen att leda till bättre förståelse för hur hälsosamma celler fungerar, men kan också komma att identifiera de tillstånd i cellen som driver sjukdomsprogression, leda till upptäckten av nya behandlingsstrategier samt ge insikter inom personanpassad medicin (Nature Reviews Genetics, 2023).

Single-cell RNA sequencing (scRNA-seq) är ett samlingsnamn på en familj av metoder som kvantifierar förekomsten av RNA-molekyler i en cell, vilket ger en bild av cellens genuttryck (Seibert & Aghdam, n.d.). Produkten av scRNA-seq är en matris, där varje punkt i matrisen representerar hur mycket en viss gen uttrycks i en undersökt cell (*Generating a Gene Expression Matrix*, 2020). En specifik form av scRNA-seq är single-nucleus RNA sequencing (snRNA-seq), i vilket endast RNA från cellkärnan kvantifieras.

Celltyp och celltillstånd

Traditionellt har cellers typ kategoriserats efter plats i kroppen, utseende och funktion. Därtill har man kategoriserat celler efter deras tillstånd; såsom proliferative (genomgår cellförökning), quiescent (vilande), motile (rörlig) eller apoptotic (genomgår programmerad celledöd). Förståelsen av cellernas tillstånd är ett område under utveckling på grund av utvecklingar inom teknologier som single cell imaging och nya analysmetoder. Mätning av transkriptomet i den

enskilda cellen ger utökade möjligheter att identifiera grupper av gener som uttrycks inom olika celltyper eller celltillstånd, eller under särskilda förutsättningar (Rafelski & Thiriot, 2024). Förståelsen av transkriptomet som indikativt på sjukdom på cellnivå kommer att vara en viktig del av detta projekt.

Black-box modeller, tolkningsbarhet (Interpretability) och BINNs

I takt med att maskininlärningsmodeller (ML-modeller) har ökat i effektivitet och beräkningskraft, och i och med att flera modeller kan hitta komplexa icke-linjära samband i data, har förståelsen för hur dessa modeller fungerar internt minskat drastiskt. I "värsta fall" sker en oerhört stor mängd beräkningar i modellen som inte låter sig till någon mänsklig förståelse, vilket då kallas en "black-box modell". Neurala nätverk är ett exempel på en typ av black-box modell, där indata och utdata är väldefinierade, men vad som händer där emellan i deras så kallade "hidden layers" är helt okänt (Kosinski, 2024). Problem kan uppstå när black-box modeller används i kontexter där förståelse är särskilt viktigt, till exempel inom diagnostisering i sjukvården. Här är det inte etiskt försvarbart att låta en sådan modell styra över eventuell behandling, och det finns således ett stort hinder för användandet av en teknik med i övrigt oerhört stor potential.

På grund av detta problem har det utvecklats en ny typ av modell med fokus på tolkningsbarhet, utan att nödvändigtvis minska effektiviteten av nätverket. I en biologisk kontext har så kallade Biologically Informed Neural Networks (BINNs) tagit plats. Denna typ av neurala nätverk anpassas för att inkludera ett underliggande biologiskt system genom att använda tillgänglig kunskap om gener, biologiska reaktionsvägar, och processer (Selby et al., 2025). Till skillnad från ett konventionellt nätverk där neuronerna generellt sett är kopplade till alla andra i nästa lager (fully connected networks), har neuronerna och dess länkar i BINNs en konkret biologisk betydelse. Detta gör dels att det krävs mycket färre noder och länkar, samt att dessa går att tolka individuellt, vilka är två huvudsakliga faktorer till BINNs utökade tolkningsbarhet. På grund av detta minskade antal noder och länkar kräver BINNs kraftigt begränsade resurser för beräkning jämfört med konventionella neurala nätverk, vilket ytterligare ökar deras potential.

Maskininlärning inom Alzheimerforskningen och användning av BINNs

Inom Alzheimerforskningen har maskininlärning tidigare använts för att upptäcka biomarkörer, att utföra sjukdomsklassificering, detektera subtyper, att förutse progressionshastighet samt för att undersöka möjligheten att återanvända existerande läkemedel inom Alzheimersbehandling. För att åstadkomma detta har ML-metoder kombinerats med transkriptomik, genomik, epigenetik, metabolomik, klinisk data och medicinska avbildningsmetoder, samt använt prover tagna från saliv, cerebrospinalvätska, blod och hjärnceller. Data från medicinska avbildningsmetoder har varit vanligt använt inom studier kring att diagnostisera Alzheimers med hjälp av maskininlärning, men även neuropsykologisk samt multimodal data har använts för detta syfte. Bland de specifika ML-tekniker som använts för diagnostik finns bland annat support vector machines, multi-layer perceptrons, autoencoders, convolutional neural networks, deep learning och språkmodeller (Li, 2021).

Biologically Informed Neural Networks har använts inom ett flertal användningsområden utanför Alzheimersforskningen; däribland inom utveckling av läkemedel, att förutse effektiviteten av behandlingar och att undersöka cellulära processer. En senare utveckling är att applicera BINNs

på data från single-cell sequencing, vilket har kunnat klarlägga nätverk för genreglering och visat på heterogenitet i celler av samma typ (Selby et al., 2025).

Hartman et al. (2023) har använt ett BINN för att, bland annat, utföra sjukdomsklassificering inom Covid-19 och sepsis. För att åstadkomma detta designade forskningsgruppen ett neuralt nätverk som använder sig av domänkunskap i form av biologiska reaktionsvägar, där bulk proteom-data används som input. Den resulterande modellen kan inte bara klassificera sjukdomstillstånd, utan dessutom identifiera potentiella biomarkörer som delar in Covid-19 och sepsis i sub-fenotyper. Dessutom erbjuder modellen molekylära förklaringar för sub-fenotypernas symtom (Hartman et al., 2023).

Syfte

Syftet med detta projekt är att skapa och jämföra två ML-modeller; ett Biologically Informed Neural Network (BINN) och ett Deep Neural Network (DNN), för att undersöka om BINNs kan prestera bättre för klassificering av Alzheimers sjukdom (AD) än konventionella DNNs, baserat på single-cell transcriptomics data från patienter som deltagit i en Alzheimers-studie. Resultatet utvärderas utifrån flera faktorer, som modellernas tolkningsbarhet (eng. interpretability), deras kapacitet att diagnostisera AD (till exempel F1-score, specificitet etc.), samt hur mycket resurser som krävs för att träna modellerna.

Problem/Uppgift

Alzheimers sjukdom orsakar förändringar på hjärnan flera år innan tydliga symtom som minnesförlust uppvisas, vilket medför en betydande klinisk utmaning att diagnostisera sjukdomen i ett tidigt skede. Single-nucleus RNA-sekvensering (snRNA-seq) är en lovande väg framåt. Denna metod tillgängliggör data från vilken kan göras analyser av genuttryck, vilket skulle kunna avslöja sjukdomsmönster långt innan de första kliniska symtomen är märkbara. Datan som produceras av snRNA-seq är däremot tekniskt utmanande att analysera, då det handlar om tiotusentals olika gener från ett begränsat antal patienter, vilket innebär en komplex högdimensionell datamängd. Detta gör det svårt att med precision skilja faktiska sjukdomssignaler från naturligt brus.

För att hantera problematiken med enorma datamängder är ML-modeller ett passande verktyg på grund av deras starka egenskaper att effektivt behandla data och filtrera brus. När det gäller att förstå och förutspå från stora mängder komplexa data är neurala nätverk särskilt potenta tack vare sin förmåga att identifiera invecklade, icke-linjära mönster som ofta förblir upptäckta av traditionella statistiska metoder. Genom sin hierarkiska struktur kan dessa modeller lära sig att prioritera de mest relevanta mönstren, vilket är avgörande vid analys av högdimensionell data såsom genuttryck. I anknytning till nätverkens komplexitet tillhör ofta utmaningen att vägen till resultatet är svårtolkat. Det är alltså svårt att härleda vilka biologiska orsaker som faktiskt ligger till grund för prognosen. Således skapas behovet av en mer tolkningsbar modell som har lika hög precision och dessutom är biologiskt grundad.

Här har Biologically Informed Neural Networks (BINNs) vuxit fram som ett lovande alternativ. Till skillnad från konventionella neurala nätverk, där arkitekturen ofta bestäms genom trial-and-error, integrerar BINNs existerande biologisk kunskap direkt i nätverkets struktur. Detta

görs genom att låta nätverkets neuroner och lager motsvara verkliga biologiska strukturer, såsom gener, proteiner och reaktionsvägar (pathways). Denna metod omvandlar neurala nätverk från en ogenomskinlig matematisk funktion till något som liknar en karta över biologiska processer.

BINNs förväntas ha potential att vara ett kraftfullt verktyg vid analys av Alzheimers, eftersom den tillåter att inte bara klassificera en patient som sjuk eller frisk, utan även möjliggör identifiering av vilka specifika biologiska faktorer som kan vara mest avgörande för diagnosen. Genom att begränsa nätverkets kopplingar till att endast följa kända interaktioner minskar dessutom risken för att modellen lär sig av oriktig data såsom brus, vilket leder till en starkare generaliseringsförmåga. Projektet syftar därför till att utvärdera om BINNs kan leverera en precision som är jämförbar, eller bättre, än konventionella neurala nätverk på att klassificera hjärnceller från postmortem-patienter som friska eller sjuka med avseende på Alzheimer's sjukdom. BINN-modellen kommer alltså att ställas mot ett konventionellt neuralt nätverk, samt ett fåtal baseline-modeller, för utvärdering av bl.a. precision. Utöver detta fokuserar projektet även på att analysera modellens tolkningsbarhet genom identifiering av vilka specifika gener och biologiska reaktionsvägar som BINN-modellen använder för att klassificera patienter som friska eller sjuka.

En betydelsefull aspekt i detta projekt är användningen av data från avlidna patienter, vilket kan orsaka brister i slutledningen. Vävnadsprover från avlidna blir med tiden påverkade av biologisk nedbrytning och därmed försämrade kvalitet på datan eftersom mängden brus i datan ökar. Det ställs därför höga krav på modellens förmåga att separera sjukdomssignaler från de förändringar som sker naturligt efter döden.

Till sist ger projektet möjlighet att undersöka om BINN-modellen kan bibehålla sin precision även när den är begränsad till en enskild eller mindre grupp celltyper. Till exempel skulle det kunna vara intressant att begränsa modellen till att tränas på viktiga aktörer i sjukdomens progression, som mikroglia (immunceller i det centrala nervsystemet).

I vår litteraturstudie för denna planeringsrapport har vi hittat artiklar som behandlar Alzheimers och maskininlärning, BINNs kombinerat med single-cell data, och BINNs kombinerat med bulkdata för sjukdomsklassificering utanför Alzheimerforskningen. Däremot saknas, så vitt vi vet, forskning som berör BINNs för sjukdomsklassificering av Alzheimers baserat på single-cell transcriptomics data, vilket medför att detta är ett intressant forskningsområde.




Fig. 1 Forskningsöversikt

Avgränsningar

I arbetet väljer gruppen att se avsnittet om avgränsningar mer som vad vi preliminärt anser inte ligger i huvudfokus, snarare än en definitiv uteslutning. Självklart får arbetets utveckling framöver avgöra vilka vägar som är eller inte är möjliga att gå. Utifrån den data som ursprungligen används är en avgränsning att alla våra modeller tränas på postmortem-hjärnceller. Eftersom datan uteslutande innehåller genetisk information för Alzheimerpatienter är detta den enda sjukdom som berörs i klassificeringen.

Gällande ML-modellerna, så kommer två stycken vara i huvudfokus; ett BINN och ett konventionellt neuralt nätverk. Fokus kommer inte ligga på att optimera algoritmerna, utan istället på att bygga, utvärdera, och förklara modellerna. Eventuellt kommer en enklare modell användas som baslinje, exempelvis logistisk regression.

Vi planerar heller inte att göra en djupgående biologisk analys av resultaten, även om en del av arbetet kommer att vara att undersöka modellernas förklaringsförmåga (eng. explainability) och tolkningsbarhet (eng. interpretability). Att inte ha biologin som huvudfokus är också rimligt med tanke på att gruppens medlemmars bakgrund generellt ligger mer åt det beräkningstekniska hållet än det biologiska eller biotekniska.

Avslutningsvis betonas återigen att detta är planen gällande avgränsningar nu i början av arbetet. Hur projektet utspelar sig och vilka vägar som är möjliga att ta återstår att se, men i det nuvarande skedet är avgränsningarna nämnda ovan rimliga att förhålla sig till.

Metod/Genomförande

Problemformulering

Det första momentet är att definiera mål och mått för utvärdering. Vi har ett binärt klassificeringsproblem för diagnostisering av Alzheimers sjukdom, där vi kommer att jämföra två ML-modeller, i vårt fall två typer av neurala nätverk, nämligen Biologically Informed Neural Networks (BINNs) och Deep Neural Networks (DNNs). Det huvudsakliga målet är att undersöka huruvida ett BINN kan vara en bättre modell för denna typ av problem, och för att kunna göra detta behöver vi därmed mått för utvärdering av nätverken. De främsta måtten som vi kommer att använda för prestanda är ROC-AUC (Receiver Operating Characteristic Area Under the Curve) och F1-score för de två nätverken. För tolkningsbarhet analyseras biologiska reaktionsvägar (från BINN-modellen), samt så kallad feature importance med hjälp av SHAP (SHapley Additive exPlanations). Arbetet med konstruktion av modellerna och deras utvärdering kommer att utföras i Python med hjälp av ramverket PyTorch.

Data

Insamling

Detta moment är mycket viktigt då datan formar hur modellen kommer se ut och kvaliteten påverkar pålitligheten i modellens resultat. För att kvalitetssäkra datan används endast väletablerade och trovärdiga källor. Vår huvudsakliga källa är data från MIT's Computational Biology Group. (MIT, n.d.) Här presenteras data från en single-cell transcriptomic atlas av den mänskliga hjärnans prefrontala cortex, med fokus på Alzheimers sjukdom (AD). Detta är ett stort dataset av snRNA-seq data som kvantifierar genuttryck på cellnivå. Källan innehåller postmortem-prover av ett flertal olika typer av hjärnceller från 427 deltagare i ROSMAP-studierna (Religious Orders Study & Rush Memory and Aging Project). Olika nivåer av AD-patologi och kognitiv status är representerade. Datan inkluderar ~2,3 miljoner enskilda celler.

Förarbete (Preprocessing)

Ett steg i processen är att konvertera datan från ett filformat som stöds av R till ett format som kan hanteras i Python. Värt att notera är att datan troligt redan har genomgått viss preprocessing, med exklusion av celler som är av dålig kvalitet eller starkt avvikande (Mathys, 2023). Eventuellt kan vi vilja utföra ytterligare sällning av datan, till exempel att utesluta prover med stort pmi-värde (post-mortem interval).

Förståelse

Urvalsgruppen för datan är till stor del äldre vita amerikaner med en jämn könsfördelning, 215 kvinnor (50.4%) och 212 män (49.6%). Proverna har hämtats från 238 (55.7%) personer med AD-diagnos och 189 (44.3%) utan diagnos. Cellulär data, likt mycket annan celldata, kan påverkas av batch-effekter. Detta innebär att datan kan ha variationer baserat på specifikt när och var den uppmättes, samt vilka instrument som användes. Detta kan behöva hanteras med någon typ av batch-korrektion, vilket är metoder som utöver sina fördelar även riskerar att försämra verklighetsanknytningen och ge falska resultat (Zindler, 2020). En potentiellt lämplig batch-korrektionsmetod som vi skulle kunna använda är Harmony (Tran, 2020).

Träning/Testning-split

Datan kommer att delas upp i sub-set för träning och testning. Datan bör stratifieras för att försäkra att olika subgrupper från datan representeras i både sub-set för träning och testning. Eventuellt kan metoder för att dela upp datan som K-fold Cross Validation användas för att undvika overfitting och utnyttja den tillgängliga datan så effektivt som möjligt.

Modell

Baseline Models

Innan jämförelsen av BINN mot ett konventionellt DNN utförs, så kan en eller flera enklare modeller skapas som baseline; till exempel kan logistisk regression, en random forest-algoritm, eller en Support Vector Machine (SVM) användas. En sådan baseline-modell kan vara en värdefull utgångspunkt att referera till och jämföra mer avancerade ML-modeller med, och dessutom bidra med en preliminär försäkran om att datan är välhanterad och lämplig att använda i projektet.

Konventionellt DNN

Ett essentiellt steg i detta arbete är att konstruera ett konventionellt neuralt nätverk för jämförelse med ett BINN. Planen är att konstruera ett *fully connected feedforward network*. Metoder som dropout och early stopping kan användas för att undvika overfitting. Olika aktiveringsmetoder som ReLU eller GELU kommer att användas. Hyperparametrar som djup, bredd, batch size och learning rate kommer att behöva justeras. Vi kommer att lägga begränsad tid på att optimera konstruktionen av detta neurala nätverk, eftersom målet är att skapa ett neuralt nätverk som kan ge en "rättvis" jämförelse mot ett BINN.

Integrera Biologisk Kunskap (BINN)

Vi kommer att behöva söka upp en lämplig databas med information om biologiska reaktionsvägar som kan integreras i vår BINN. Vi känner redan nu till några möjliga databaser; Reactome, KEGG och Gene Ontology. Vår data innehåller gene expressions i form av läsningar av RNA, så vi behöver hitta en databas som är kompatibel. Vi kommer troligtvis behöva omvandla reaktionsvägar från formatet som finns i databasen till en datastruktur som är lämplig att integrera i ett neuralt nätverk.

Konstruera BINN

Strukturen på BINN-modellen kommer till viss del likna den som används i det konventionella neurala nätverket. Till skillnad från det konventionella nätverket kommer det dock inte att vara *fully connected*, utan det inre nätverket kommer att ha kopplingar som är begränsade av de biologiska reaktionsvägar som finns i cellen. Detta nätverk liknar således mer ett Sparse Neural Network (SNN).

Träning / Testning

Det konventionella neurala nätverket, BINN-modellen och en eventuell baseline-modell tränas på tränings-delen av den förprocessade datan i en supervised learning-miljö. Det kan eventuellt vara intressant att träna modeller på alla celltyper, samt på ett subset av celltyper (till exempel mikroglia).

Efter att modellerna är tränade kommer de att testas på testnings-subsetet av den förprocessade datan. Mätningar av till exempel accuracy, precision och ROC-AUC inhämtas och utvärderas enligt nedan.

Utvärdering (prestanda)

Ett viktigt steg i processen är utvärdering av modellernas prestanda. För detta kommer ett flertal mätetal, så kallade metrics, användas. Två mått som komplementerar varandra är recall och precision. Båda har sina nackdelar men slår man samman dem i ett harmoniskt konjugat får man F1-score, som således ger en mer nyanserad bild av modellens prestanda. Även confusion matrices kommer att användas i detta syfte.

Analys av Tolkningsbarhet (Interpretability)

För att utvärdera den tränade modellens tolkningsbarhet och säkerställa dess biologiska relevans, kommer vi att genomföra en analys med hjälp av SHAP (SHapley Additive exPlanations). SHAPs metod beräknar så kallade SHAP-värden för samtliga ingående datapunkter i modellen. SHAP-värdet av en datapunkt representerar bidraget av den specifika datapunkten till den slutgiltiga klassifikationen. I vårt fall är ingående datapunkter specifika gener, vars bidrag till klassifikationen kommer att utvärderas.

Eftersom att BINN-modellens struktur är uppbyggd kring kända biologiska hierarkier, kommer SHAP eventuellt möjliggöra en tolkning av vilka specifika reaktionsvägar som är av betydelse. Utifrån detta kan det undersökas om biologiska tolkningar relaterade till Alzheimerforskning kan göras eller ej.

Generalisering & Robusthet

Eventuellt kan modellen testas med ett annat dataset med snRNA-data från hjärnceller för att undersöka hur väl modellen generaliserar, och att säkerställa att modellen inte är överanpassad till träningsdatan. Vid jämförelse av ML-modellerna är generalisering väldigt relevant. En ML-modell som inte kan generalisera till osedd data är oduglig. Att använda sig av metoder för att undvika överanpassning kommer vara högst användbart, exempelvis dropout, cross-validation och L1/L2-regularisering (Ying, 2019, 4-5). Detta hjälper ML-modellerna att lära sig generalisera utifrån inlärningsdatan, och inte bara memorera den.

Robustheten hos ML-modellerna berättar hur prestationen hos modellerna påverkas av oförutsedda förändringar hos indatan. För att öka och utvärdera robustheten hos ML-modellerna kan brusinjektion (Zur et al., 2009, 4812) samt permutationstester utföras (Huang, 2025, 1).

Fortsättningsvis så kan subgruppsanalyser visa sig intressanta för modelljämförelse. Att undersöka huruvida grupperingar på inlärningsdatan påverkar prestanda och generalisering hos modellerna är högst relevant för att utvärdera modellernas kliniska nytta. Om exempelvis ML-modellerna enbart tränas på en grupp bestående äldre män kommer rimligtvis generalisering till hela befolkningen att vara bristande.

Resultat

Visualisering

Vid visualisering av resultat kommer framför allt tre metoder användas; confusion matrices, pathway importance plots, samt ROC-kurvor. En confusion matrix visar metodernas sanna och falska positiva svar respektive negativa svar. Med andra ord visar noggrannheten hos ML-modellen gällande klassificering av hjärnceller som sjuka eller friska, från AD. En lång diskussion kommer sedan kunna föras gällande dessa resultat, med frågor som; Vad är acceptabelt? Vad är etiskt försvarbart? Ett falskt negativt resultat kan med stor fördel argumenteras ha värre konsekvenser än ett falskt positivt resultat, men i vilken mån? Här är även F1-score samt ROC-kurvor relevanta, för att få kombinerade värden på prediktiv prestanda.

Pathway importance plots visar på vilka reaktionsvägar som påverkar slutresultatet mest, och kommer användas för den biologiska argumentationen och tolkningen bakom BINN-modellen (Hayakawa et al., 2022, 1).

Tolkning

Avslutningsvis ska resultatet tolkas, och frågeställningen som definierades i början av arbetet ska besvaras. Presterade BINN-modellen bättre än det konventionella neurala nätverket angående klassifikation av AD? Är BINN-modellen mer tolkningsbar? Generaliserar den väl till ny data? Kräver modellen mer beräkningskraft?

Utökning

Utifrån resultatet kommer områden för vidare forskning att föreslås.

Dokumentation & Reproducerbarhet

I detta slutsteg ska det säkerställas att resultatet dokumenteras väl och att möjligheter för reproduktion finns. Det kommer att skrivas en README, som instruerar användning av data samt kod (datahantering, BINN, DNN etc.). Denna kommer finnas tillgänglig längs koden i en GitHub-release, vilket säkerställer versionskontrollerad utgivning. Våra modeller och vår datahantering kommer att vara utförligt beskrivna i den slutgiltiga rapporten.

Samhälleliga och etiska aspekter

Då användningen av ML inom medicinsk forskning växer snabbt, tillkommer många etiska aspekter som måste beaktas. Nya metoder som använder ML och artificiell intelligens kan vara dyra och då finns risken att den nya tekniken endast blir tillgänglig för vissa grupper. Detta kan väcka etiska diskussioner om vem som har rätt eller möjlighet till högteknologisk sjukvård. Ett ytterligare problem är att ML kan stärka ras- och könsbaserade ojämlikheter på grund av bias i vår träningsdata. I vår studie är datan till övervägande del från vita amerikanska patienter, vilket skulle kunna leda till att modellen inte har tränats tillräckligt generellt för att ge pålitliga svar. (AD Knowledge Portal, n.d., MIT, n.d.) Dessutom finns problemet att maskiner aldrig kommer kunna ersätta mänskliga känslor och empati. Studier har visat att relationen mellan patient och läkare spelar en viktig roll i vårdens kvalitet, då tillit och emotionellt stöd kan förbättra behandlingen. Att

förlora den emotionella aspekten kan eventuellt försämra vården för patienten och då lyfts frågan om det är etiskt försvarbart att låta ML-modeller spela en alltför stor roll inom vården (Drabiak et al., 2023, 3).

Två mer långsiktiga problem som utvecklandet av maskininlärning inom sjukvård kan bidra till är automationsbias och avkvalificering. Det förstnämnda innebär att vårdpersonal förlitar sig för mycket på ML-modeller, vilket kan bidra till minskad kritisk granskning av resultaten. Avkvalificering innebär att maskininlärning blir bättre än människor på att exempelvis analysera och identifiera sjukdomar. Detta kan på sikt leda till att efterfrågan på mänsklig kompetens inom ämnet minskar och att vi till slut saknar kunskapen för att avgöra om maskinen gör biologiska fel. Eftersom sjukvårdspersonal inte heller specialiserar sig på de tekniska aspekterna bakom maskinen är det svårare för dem att identifiera maskinfel. Dessa långsiktiga risker medför att en etisk bedömning av integrationen av ML inom sjukvården är nödvändig och det är därför viktigt att utnyttja dess fördelar och minimera potentiella nackdelar (Drabiak et al., 2023, 4).

I detta projekt studerar vi post-mortem-celler från patienter där datan kommer från Alzheimerstudien ROSMAP i samarbete med forskningsplattformen *Synapse*. Datan har anonymiserats, vilket skyddar patienternas konfidentialitet och minskar risken för etiska problem kopplade till datahantering.

Efter genomfört projekt hoppas vi få ökad kunskap om hur neurala nätverk kan användas inom Alzheimersforskning och specifikt vilka fördelar eller nackdelar BINNs har jämfört med vanliga neurala nätverk. Då BINNs troligtvis är mer biologiskt tolkningsbara gentemot black-box modellerna kan detta bidra till att vi undviker problem som avkvalificering och automationsbias då resultaten måste granskas och förklaras. Mer kunskap om BINNs kommer förhoppningsvis gynna forskare inom området och Alzheimerspatienter.

Tidsplan

En grafisk tidsplan har konstruerats utifrån en GANTT-mall, där olika aktiviteter i arbetet delas upp i olika faser och de veckor som är relevanta för varje aktivitet markeras ut. Utöver detta har specifika milstolpar definierats för att ha specifika mål att sträva efter. Tidsplanen innefattar inte alla aktiviteter, då möten med handledare och möten inom gruppen inte tas med. På samma spår så är tidsplanen endast just det; en plan. Kalkylarket är tänkt att ge en bakomliggande struktur medan det samtidigt, under arbetets gång, utvecklas och revideras iterativt.

[Länk till tidsplanen](#)

Projekt:		BBTX11-VT26-07: Classifying Cellular States from Gene Expression with Interpretable Machine Learning																			TIDSPLAN							
Projektgrupp:		BBTX11-VT26-07A		Datum:		2026-02-05																						
Kurs:		Kandidatarbete		Version:		2.0																						
FAS		AKTIVITETER		MILSTÖLPAR		Planeringsöversikt per vecka																						
Uppdelning	Färgkod	Beskrivning	Beskrivning	Status	Kalendervecka:	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23			
					Lisvecka:	1	2	3	4	5	6	7	8	TerisP	1	2	Pisk	Pisk tje	3	4	5	6	7	8	T			
Inledningsfas		Diskussion och skrivande av gruppkontrakt	Färdigt gruppkontrakt	Klar		Fre																						
		Inledande litteraturstudier	-	-																								
		Skrivning av projekt- och tidsplan	Färdig planeringsrapport	-				Ons																				
		Isoplanering	-	-																								
		Förberedande databantering	-	-																								
Huvudfas		Välja och implementera pathway-databas	-	-																								
		Bygga upp modell	Färdig BiNN-modell	-									X															
		Bygga upp den alternativa modellen	Färdig alternativ modell	-									X															
		Träna modell	-	-																								
		Utvärdera modell (Interpretability VS accuracy etc.)	-	-																								
		Insamlning testdata (Generalizability test?)	-	-																								
		Testa modell på helt ny testdata (Generalizability test?)	-	-																								
		Skrivande av projektrapport	Införande av rapport	-									X (Första utkast, vid mötet)									Ons						
Slutfas		Presentation + muntlig opposition	-	-																		Ons (inlämnad)	Tors/					
		Opponering (skriftlig)	-	-																			Tors/					

Fig. 2 Tidsplan över kandidatarbete

Referenser

AD Knowledge Portal. (n.d.). *The Religious Orders Study and Memory and Aging Project (ROSMAP) Study*. AD Knowledge Portal.

[https://adknowledgeportal.synapse.org/Explore/Studies/DetailsPage/StudyDetails?Study_Name=\(ROSMAP\)](https://adknowledgeportal.synapse.org/Explore/Studies/DetailsPage/StudyDetails?Study_Name=(ROSMAP))

Alzheimer's Association. (2024). 2024 Alzheimer's disease facts and figures. *Alzheimer's & Dementia*, 20(5), 114. <https://doi.org/10.1002/alz.13809>

Alzheimer's Stages - Early, Middle, Late Dementia Symptoms | [alz.org](https://www.alz.org/alzheimers-dementia/stages). (n.d.). Alzheimer's Association. Retrieved February 9, 2026, from <https://www.alz.org/alzheimers-dementia/stages>

Drabiak, K., Kyzer, S., & Nemov, V. (2023, Maj 23). AI and machine learning ethics, law, diversity, and global impact. *British Journal of Radiology*, 96 (1150), 11. 10.1259/bjr.20220934

Generating a Gene Expression Matrix. (2020, August). UCD Bioinformatics Core Workshop. https://ucdavis-bioinformatics-training.github.io/2020-August-intro-scRNAseq/data_reduction/Expression_Matrix

- Hao, M., & Chen, J. (2025, 7 1). Trend analysis and future predictions of global burden of alzheimer's disease and other dementias: a study based on the global burden of disease database from 1990 to 2021. *BMC Medicine*, 23(378), 18.
<https://doi.org/10.1186/s12916-025-04169-w>
- Hartman, E., Scott, A. M., Malmström, J., Mohanty, T., Vaara, S. T., Malmström, L., & Malmström, J. (2023, September 2). Interpreting biologically informed neural networks for enhanced proteomic biomarker discovery and pathway analysis. *Nature Communications*, 14(5359).
- Hayakawa, J., Seki, T., Yoshimasa, & Ohe, K. (2022, 6 24). Pathway importance by graph convolutional network and Shapley additive explanations in gene expression phenotype of diffuse large B-cell lymphoma. *PLoS ONE*(6), 17(6), 1.
<https://doi.org/10.1371/journal.pone.0269570>
- Huang, P.-H. (2025, 8 30). Residual permutation tests for feature importance in machine learning. *British Journal of Mathematical and Statistical Psychology*, 00(00), 1-25.
<https://doi.org/10.1111/bmsp.70009>
- Kosinski, M. (2024, October 29). *What Is Black Box AI and How Does It Work?* IBM. Retrieved February 9, 2026, from <https://www.ibm.com/think/topics/black-box-ai>
- Li, Z. (2021, December 09). Applied machine learning in Alzheimer's disease research: omics, imaging, and clinical data Open Access. *Emerging Topics in Life Sciences*, 5(6), 765-777. <https://doi.org/10.1042/ETLS20210249>
- Mathys, H. (2023, September 28). Single-cell atlas reveals correlates of high cognitive function, dementia, and resilience to Alzheimer's disease pathology. *Cell*, 186(20), 4365-4385.
<https://doi.org/10.1016/j.cell.2023.08.039>
- MIT. (n.d.). *Single-cell transcriptomic atlas of the aged human prefrontal cortex*. AD/Aging Brain Atlas. https://compbio.mit.edu/ad_aging_brain/
- National Human Genome Research Institute. (2020, August 15). *Biological Pathways Fact Sheet*. National Human Genome Research Institute (NHGRI). Retrieved February 9,

2026, from

<https://www.genome.gov/about-genomics/fact-sheets/Biological-Pathways-Fact-Sheet>

National Human Genome Research Institute. (2026, 02 09). *Gene Expression*. National Human

Genome Research Institute (NHGRI). Retrieved February 9, 2026, from

<https://www.genome.gov/genetics-glossary/Gene-Expression>

Nature Reviews Genetics. (2023, August). A focus on single-cell omics. *Nature Reviews*

Genetics, 24, 485. <https://doi.org/10.1038/s41576-023-00628-3>

Navigating Treatment Options | *alz.org*. (2026). Alzheimer's Association. Retrieved February 9,

2026, from

<https://www.alz.org/alzheimers-dementia/treatments/navigating-treatment-options>

Rafelski, S. M., & Thiot, J. A. (2024, May 23). Establishing a conceptual framework for holistic

cell states and state transitions. *Cell*, 187(11), 2633-2651.

<https://www.cell.com/cell/fulltext/S0092-8674%2824%2900461-6>

Rogers, K., & Griffiths, A. J. (n.d.). *Omics* | *Description, Fields, & Applications*. Britannica.

Retrieved February 9, 2026, from <https://www.britannica.com/science/omics>

Seibert, C., & Aghdam, S. (n.d.). *Introduction to single cell RNA-Seq*. National Cancer Institute

Center For Cancer Research.

https://bioinformatics.ccr.cancer.gov/docs/getting-started-with-scrna-seq/Intro_to_scRNA-Seq/

Selby, D. A., Sprang, M., Ewald, J., & Vollmer, S. J. (2025, June). Beyond the black box with

biologically informed neural networks. *Nature Reviews Genetics*, 26, 371-372.

<https://doi.org/10.1038/s41576-025-00826-1>

Tran, H. T. N. (2020, January 16). A benchmark of batch-effect correction methods for

single-cell RNA sequencing data. *Genome Biology*, 21(1), 12.

<https://doi.org/10.1186/s13059-019-1850-9>

Valiukas, Z., Tangalakis, K., Apostolopoulos, V., & Freehan, J. (2025, January 1). Microglial

activation states and their implications for Alzheimer's Disease. *The Journal of*

Prevention of Alzheimer's Disease, 12(1), 16.

https://www.sciencedirect.com/science/article/pii/S2274580724006058?pes=vor&utm_source=clarivate&getft_integrator=clarivate

Ying, X. (2019). An Overview of Overfitting and its Solutions. *Journal of Physics: Conference Series*, 1168(2), 1-6. 10.1088/1742-6596/1168/2/022022

Zindler, T. (2020, June 30). Simulating ComBat: how batch correction can lead to the systematic introduction of false positive results in DNA methylation microarray studies. *BMC Bioinformatics*, 21(271), 15. <https://doi.org/10.1186/s12859-020-03559-6>

Zur, R. M., Jiang, Y., Drukker, K., & Pesce, L. L. (2009, 9 25). Noise injection for training artificial neural networks: A comparison with weight decay and early stopping. *Medical Physics*, 36(10), 4810-4818. <https://doi.org/10.1118/1.3213517>